UX UI Measurement

Satisfaction

UX UI Measurement - HEART

Focus on creating a product-led UX, approach shifts the balance in favor of the user on improving the product experience, instead of over-relying on sales, marketing and support scale.

Happiness	**E**ngagement	**A**doption	**R**etention	**T**ask Success
วัดความพึงพอใจผ่านแบบสอบถาม สัมภาษณ์ คะแนนรีวิว และค่า NPS (Net Promoter Score)	วัดความถี่และระยะเวลาที่ผู้ใช้เข้ามามีปฏิสัมพันธ์กับระบบ เช่น เวลาที่ใช้ในแอป	วัดอัตราการใช้งานฟีเจอร์ใหม่หรือจำนวนผู้ใช้ใหม่ในช่วงเวลาหนึ่ง	วัดอัตราการกลับมาใช้งานซ้ำและลดการเลิกใช้งาน (Churn Rate)	วัดประสิทธิภาพการทำงานให้สำเร็จ เช่น อัตราความสำเร็จ (Task success rate) และเวลาที่ใช้ทำภารกิจ

HEART on UX

	GOALS	SIGNALS	METRICS
Happiness	Users find the app helpful, fun, and easy to use	• Responding to surveys • Leaving 5-star ratings • Leaving user feedback	• Net Promoter Score • Customer satisfaction rating • Number of 5-star reviews
Engagement	Users enjoy app content and keep engaging with it	• Spending more time in the app	• Average session length • Average session frequency • Number of conversions *(consuming content, uploading files, purchases, etc.)*
Adoption	New users see the value in the product or new feature	• Downloading, launching app • Signing up for an account • Using a new feature	• Download rate • Registration rate • Feature adoption rate
Retention	Users keep coming back to the app to complete a key action	• Staying active in the app • Renewing a subscription • Making repeat purchases	• Churn rate • Subscription renewal rate
Task Success	Users complete their goal quickly and easily	• Finding and viewing content quickly • Completing tasks efficiently	• Search exit rate • Crash rate

https://medium.com/@Vini.Bansal/product-management-metrics-heart-framework-to-improve-ux-fa73c08b91fb

How the HEART Framework Works

HEART provides five complementary dimensions of user value. For each dimension, teams use the GSM method—define a Goal, identify Signals that indicate progress, and choose specific Metrics—to create a focused measurement plan for a feature or journey.

Happiness

Subjective attitudes toward your product or feature

Examples: In-app CSAT (1–5), NPS, survey/review sentiment, task-level satisfaction

Use it to: Capture perceived quality and delight—especially after key flows such as checkout, claim resolution, and onboarding.

Engagement

Depth and frequency of product use by active users

Examples: Sessions/user, time on task (when value-correlated), feature usage depth, DAU/MAU, meaningful interactions/session

Use it to: Ensure activity reflects value, not idle time or forced clicks.

Adoption

New users or existing users starting to use a feature

Examples: % of eligible users who try a feature, first-week activation, first-time checkout, % enabling a new tool

Use it to: Track uptake of launches and upgrades; inform onboarding and education.

Retention

Rate at which users return or stay subscribed over time

Examples: D7/D30 retention, cohort curves, repeat purchase rate, churn/cancel rates, subscription renewal

Use it to: Validate durable value; link to LTV and payback.

Task Success

Effectiveness and efficiency in completing key tasks

Examples: Success rate, error rate, time to complete, steps/handoffs, abandonment in a flow

Use it to: Drive UX improvements in critical flows such as search → PDP → checkout, claim filing, and account opening.

The GSM method (Goals–Signals–Metrics)

Goals

Plain-language outcomes for a feature or journey (e.g., 'Make it effortless to find and buy a product on mobile').

→

Signals

Observable behaviors or perceptions that indicate progress (e.g., fewer back-and-forth page visits, higher first-result click, positive post-checkout CSAT).

→

Metrics

Specific, reliable measurements (e.g., mobile checkout success rate, median time to checkout, PDP add-to-cart rate, post-checkout CSAT ≥ 4).

https://umbrex.com/resources/frameworks/marketing-frameworks/heart-framework-happiness-engagement-adoption-retention-task-success/

When to Use HEART

Use HEART whenever you need user-centered, scalable metrics to steer product and growth decisions.



Company types

Consumer apps and ecommerce, marketplaces, B2B SaaS/PLG, fintech, media, and public-sector digital services.



Use cases

Redesigning a core flow (search/checkout), launching features, instrumenting onboarding and activation, establishing product health scorecards, and tying UX improvements to business outcomes.



Data / time

A first HEART+GSM plan can be built in 2–4 weeks. Instrumentation and baselining may take another 2–6 weeks depending on data maturity.



Planning horizon

Use HEART for both near-term experiments and long-term product strategy. Review metrics regularly as goals evolve.



Especially powerful when



Teams argue over vanity metrics vs. value

HEART creates a shared language and aligns teams on what matters.



You need to compare features consistently

HEART provides a consistent frame so you can compare apples to apples without drowning in dashboards.



PLG motions require tying UX to outcomes

HEART links user experience to activation, retention, and revenue—the metrics that drive growth.



Less suitable or needs adaptation when



Outcomes are purely offline

If value cannot be proxied digitally, rely more on surveys, interviews, and observational research.



Minimal telemetry or poor identity stitching

Fix instrumentation and identity first so metrics are trustworthy and comparable.



Extremely low-volume contexts

Statistical tracking will be noisy; emphasize qualitative insights and task studies for Task Success and Happiness until you scale.

https://umbrex.com/resources/frameworks/marketing-frameworks/heart-framework-happiness-engagement-adoption-retention-task-success/

How to Apply the HEART Framework: Step-by-Step

Translate business goals into user-centered metrics using HEART and GSM, then operationalize them through measurement, experimentation, and economics linkage.

HEART + GSM logic

Business goals → HEART dimensions → Goal / Signal / Metric → operating cadence & experiments

1



Align on scope and business goals

Define the product area or journey (e.g., mobile discovery and checkout) and the business outcomes (e.g., conversion, returns, D30 retention). HEART translates these into user-centered metrics.

2



Map key tasks and users

Identify primary tasks such as search, compare, add-to-cart, and checkout, plus user segments like new vs. returning, mobile vs. desktop, and high-value cohorts. Note constraints such as latency, inventory, and regulation.

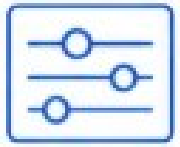
3



Run GSM for each HEART category

For each HEART dimension, define a Goal, the Signals that show progress, and the Metrics that will measure it.

4



Choose a minimal, balanced metric set

Select 1–2 metrics per relevant HEART category. Prioritize reliability, sensitivity to change, and diagnostic value. Document definitions and calculation logic.

5



Instrument and validate

Implement event tracking, survey triggers, and logging. Validate data quality through event coverage, bot filtering, identity match, and spot checks.

6



Baseline and set targets

Measure current performance by cohort and segment, then set credible quarterly targets aligned to OKRs.

7



Integrate into your operating cadence

Put HEART on feature scorecards and product health dashboards. Review weekly in standups and monthly in product councils.

8



Experiment and improve

Use HEART metrics as primary and guardrail KPIs in A/B tests. Improve one dimension without harming others, and record learnings in a shared repository.

9



Link to economics

Connect HEART improvements to conversion, CAC, LTV, and payback. Example: better Task Success can lift conversion and margin; better retention can raise LTV.

10

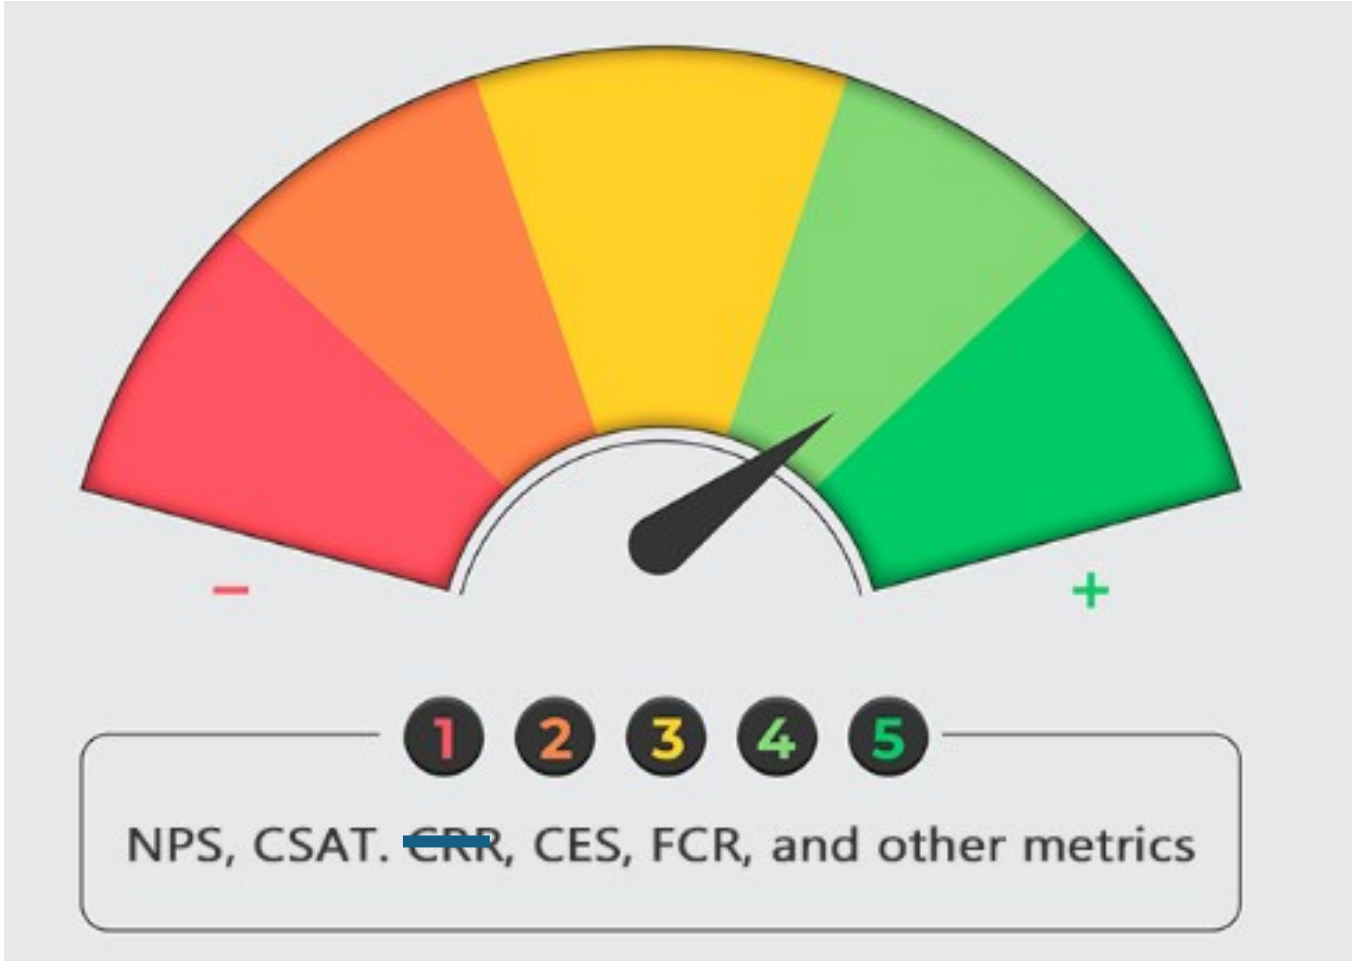


Refine the metric set periodically

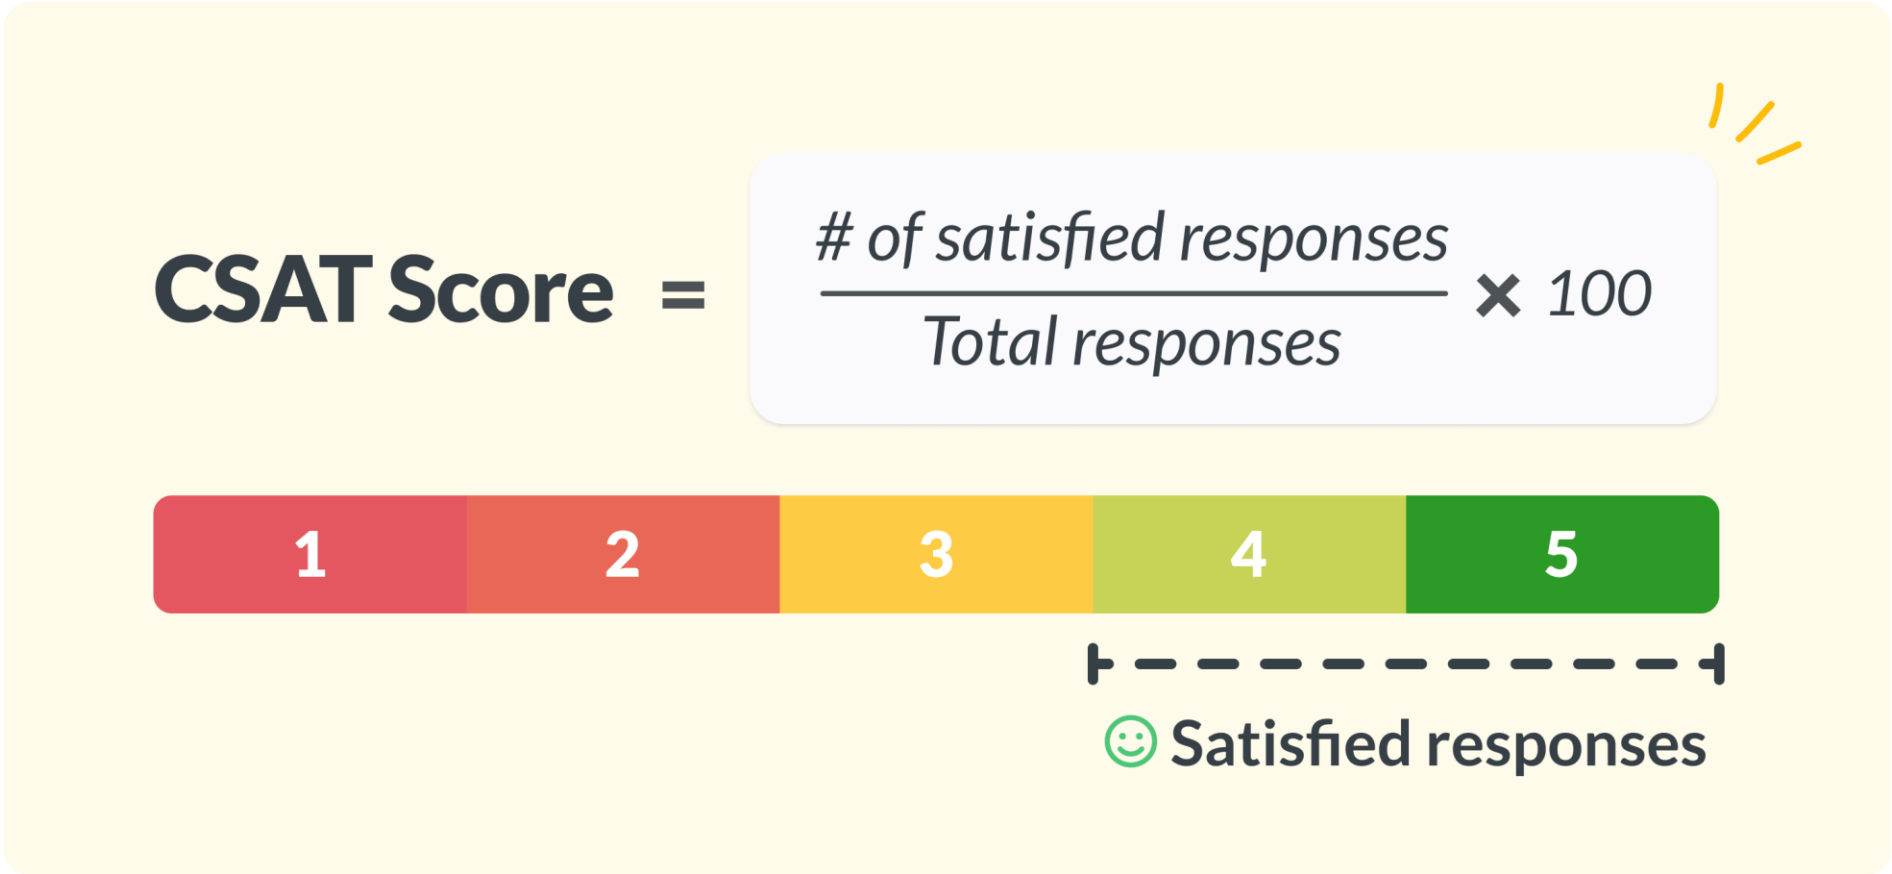
Quarterly, prune zombie metrics, recalibrate thresholds, and add or remove measures as product and strategy evolve. Keep the set small and relevant.

https://umbrex.com/resources/frameworks/marketing-frameworks/heart-framework-happiness-engagement-adoption-retention-task-success/

The Metrics to Measure User Satisfaction



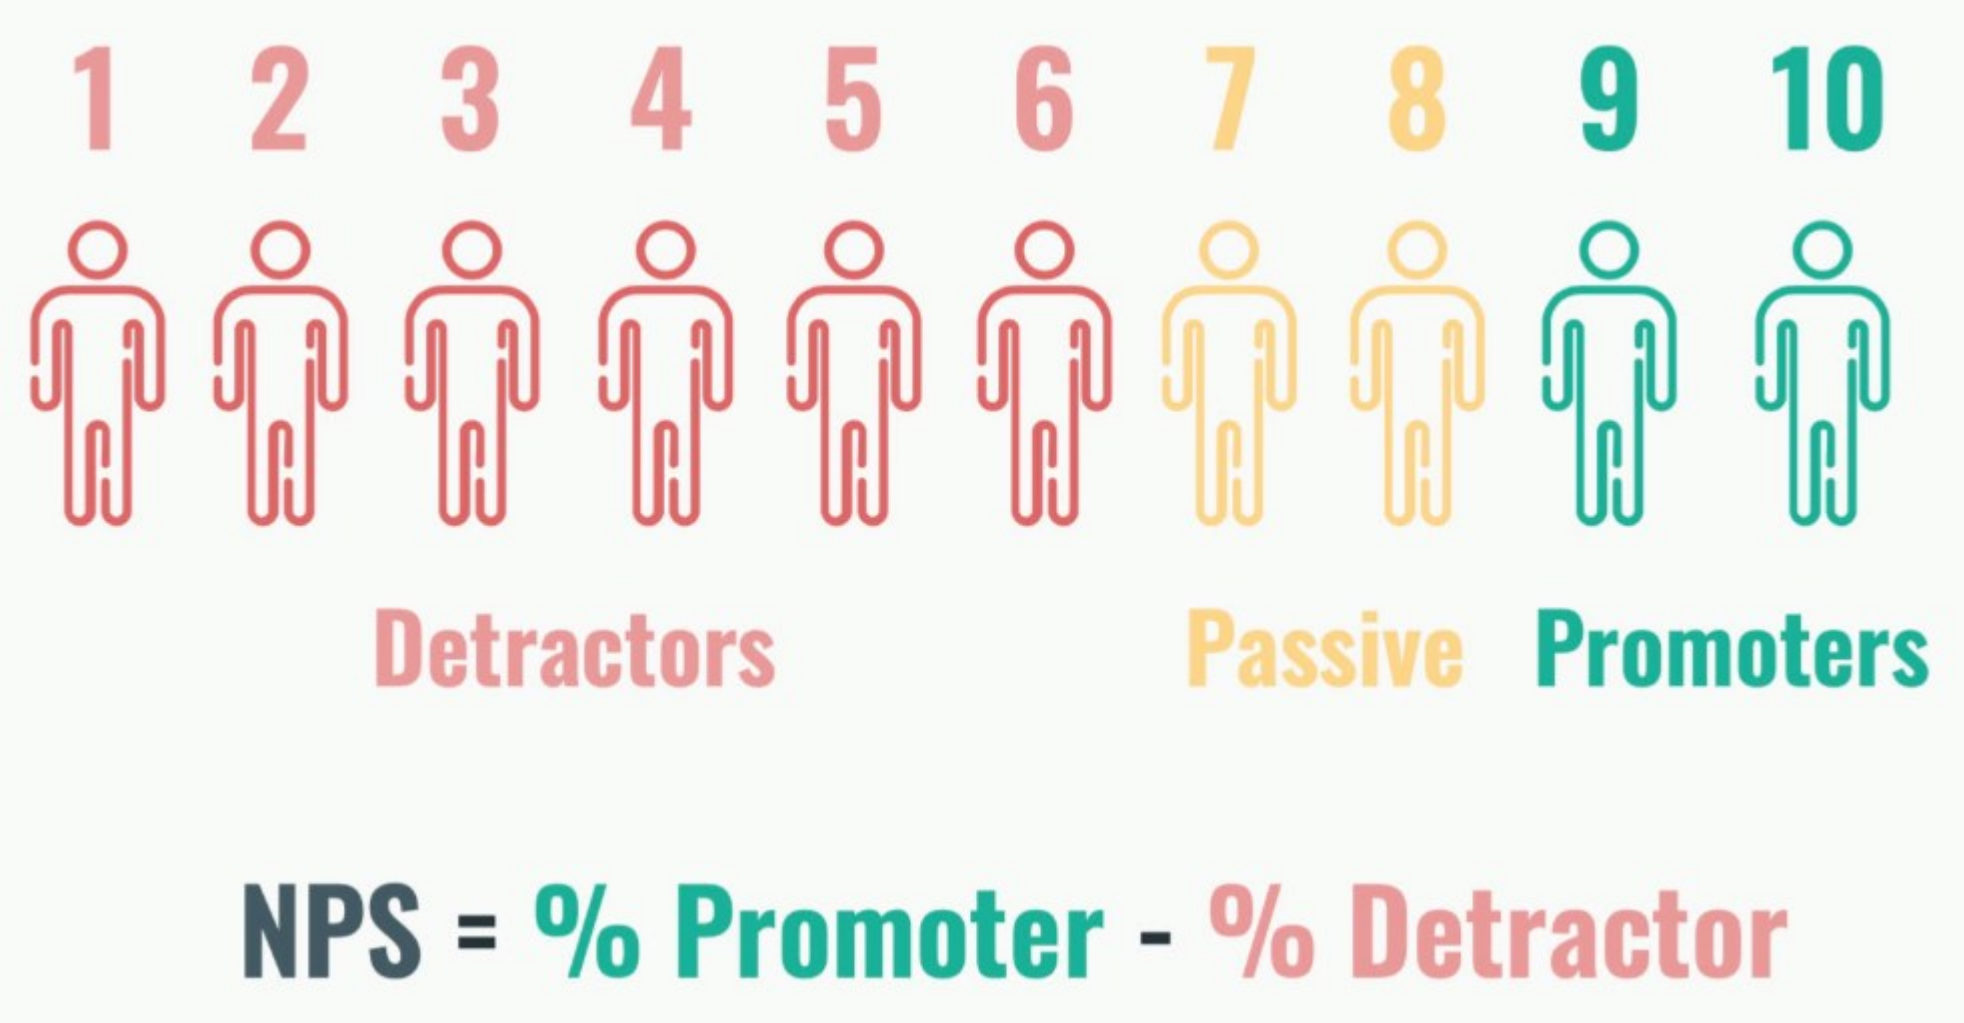
CSAT (Customer Satisfaction Score)

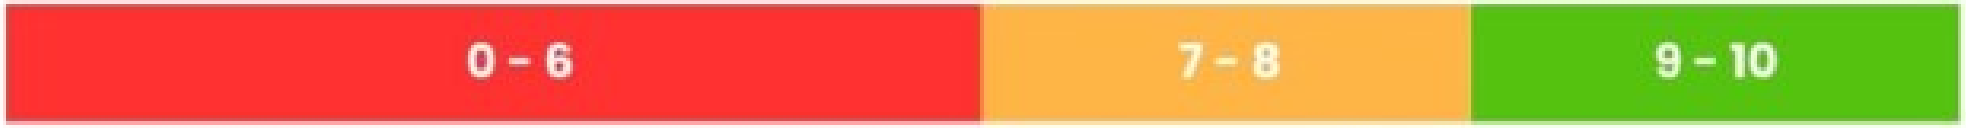


CSAT (Customer Satisfaction Score)



NPS (Net Promoter Score)





ลูกค้าที่ไม่พึงพอใจ
Detractors

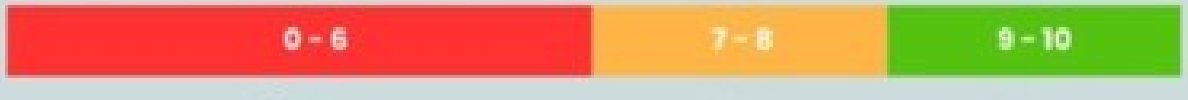
ลูกค้าที่พึงพอใจในระดับกลาง
Passives

ลูกค้าที่พึงพอใจมาก
Promoters

NPS = **%** ลูกค้าที่พึงพอใจมาก **Promoters** − **%** ลูกค้าที่ไม่พึงพอใจ **Detractors**

คะแนน	ความหมาย
-100 - 0	ต้องรีบพัฒนาสินค้า
0 - 30	สินค้าดี
30 -70	สินค้าดีมาก
70 -100	สินค้ายอดเยี่ยม

Example



50 คน 200 คน 750 คน

70 = **75%** ลูกค้าที่พึงพอใจมาก **Promoters** − **5%** ลูกค้าที่ไม่พึงพอใจ **Detractors**

สินค้าดีมาก

CSAT

Customer Satisfaction Score



Measures how satisfied a customer is with specific area of your business.

VS

NPS

Net Promoter Score



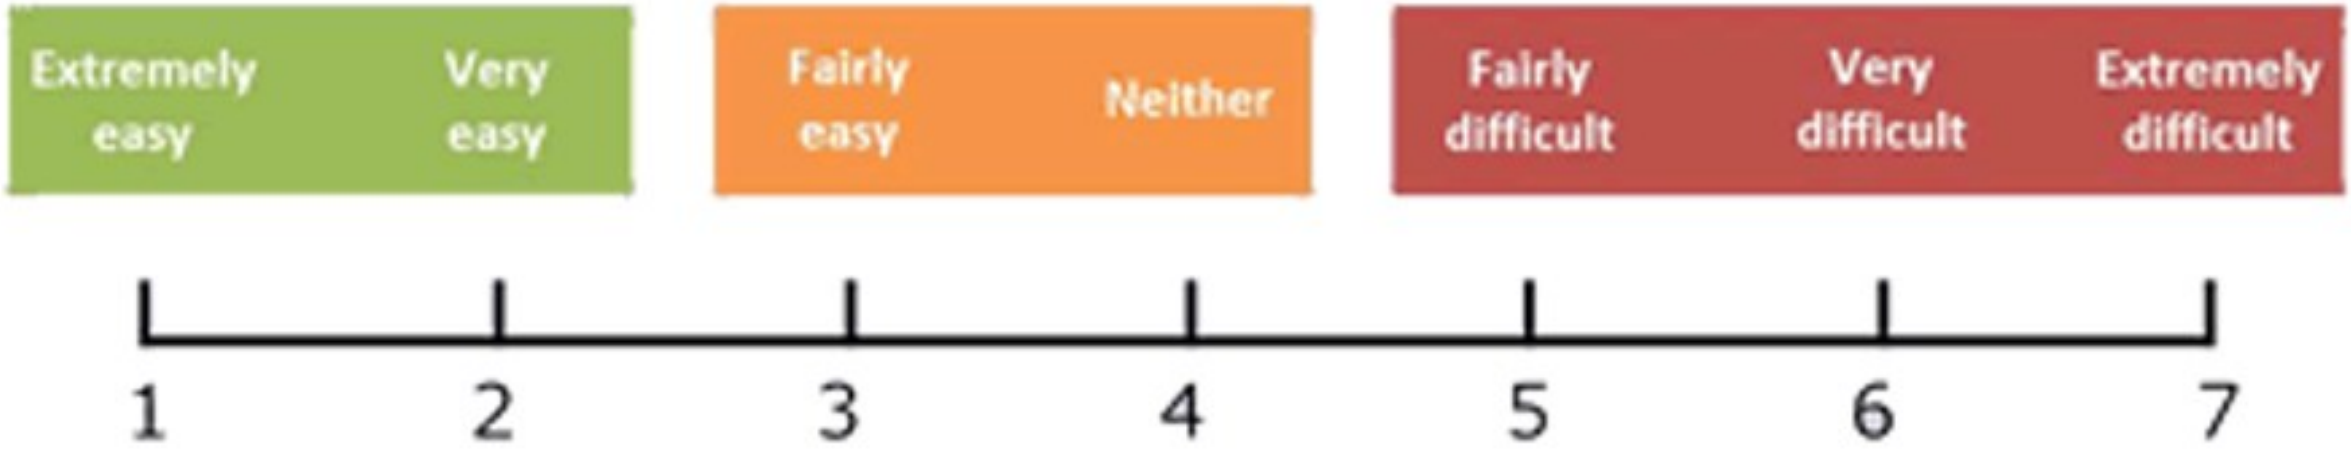
Measures overall customer loyalty towards your brand.

CES (Customer Effort Score)

How easy it is



CES (Customer Effort Score)



CSAT

Customer Satisfaction Score



Measures Overall Customer Satisfaction

NPS

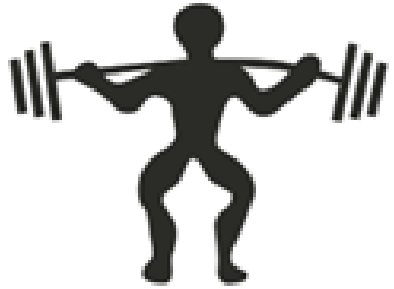
Net Promoter Score



Measures Likelihood of Customer Recommendations

CES

Customer Effort Score



Measures Level of Customer Effort Expended

CSAT
Customer Satisfaction

Are you satisfied with ...?



To measure the quality of a service / product

CES
Customer Effort Score

How easy was it ...?

7 6 5 4 3 2 1

Very difficult — Very easy

To find out how it would be easier to be our customer

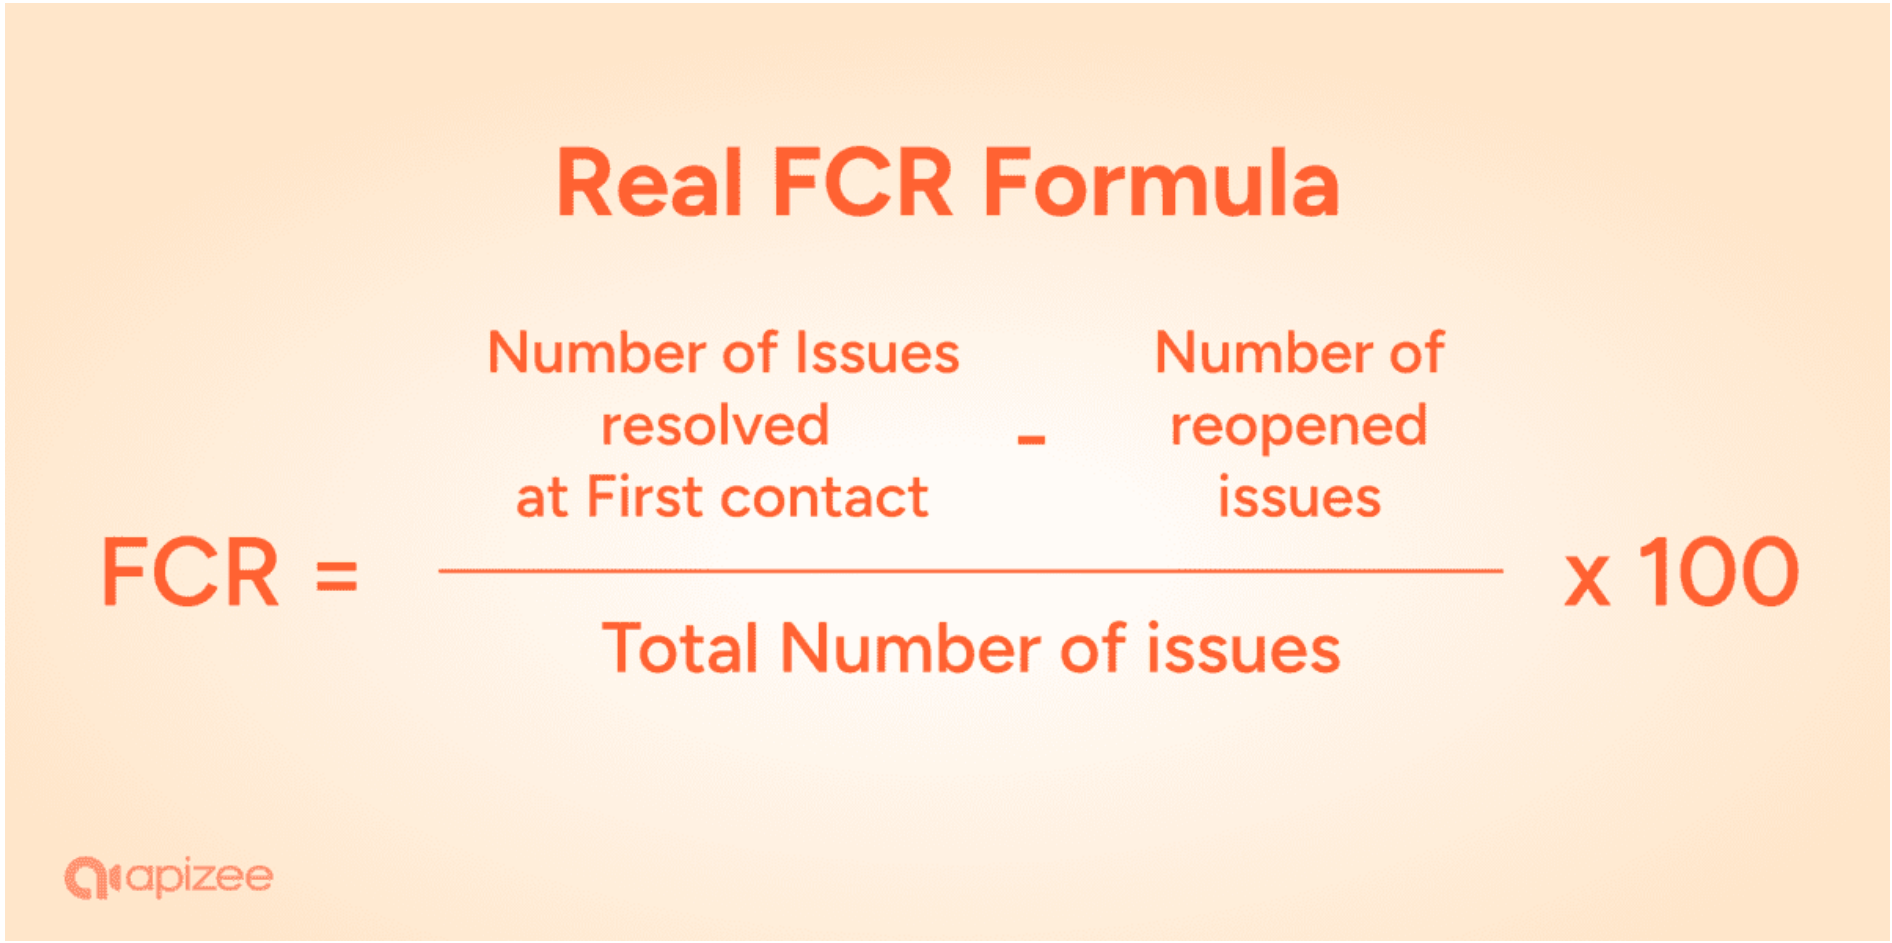
NPS
Net Promoter Score

Would you recommend us ...?

0 1 2 3 4 5
6 7 8 9 10

To measure customer loyalty

FCR (First Call Resolution)



FCR (First Call Resolution)



Why Statistics is important for UX UI

- การใช้สถิติในงาน UX/UI ช่วยลดความเสี่ยงจากการตัดสินใจด้วยความรู้สึก
- แก้ปัญหาการใช้ข้อมูลเชิงคุณภาพกลุ่มตัวอย่างน้อยเกินไป
- เปลี่ยนความเห็นให้เป็นตัวเลข
- ทำให้ข้อมูลที่ได้น่าเชื่อถือมากขึ้น
- แก้ไขปัญหาที่จะเกิดขึ้นจากการใช้ข้อมูลเชิงคุณภาพวัดผล

Statistics

เปรียบเทียบค่าเฉลี่ย

- ANOVA : one-way, two-way
- T-test : paired t-test
- Repeated Measures

ข้อมูลเชิงกลุ่ม

- Chi-square test

หาความสัมพันธ์

- Correlation : Pearson, Spearman
- Regression : Linear, Logistic

T-test

- วิธีการทดสอบทางสถิติที่ใช้เปรียบเทียบค่าเฉลี่ยของข้อมูลเพื่อดูว่ามีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติหรือไม่

- หาก p-value **น้อยกว่า** ระดับนัยสำคัญที่กำหนด (เช่น $p < 0.05$) แปลว่าข้อมูลทั้งสองกลุ่มมีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติ
- หาก p-value **มากกว่า** ระดับนัยสำคัญ (เช่น $p > 0.05$) แปลว่าไม่มีความแตกต่างกันอย่างมีนัยสำคัญ

- One sample t-test
- Independent samples t-test
- Paired หรือ dependent samples t-test

One sample t-test

❑ One sample t-test ใช้เมื่อ: ต้องการเปรียบเทียบค่าเฉลี่ยของกลุ่มตัวอย่าง 1 กลุ่ม กับค่าเป้าหมายหรือค่าที่กำหนดไว้ล่วงหน้า

- **ตัวอย่าง**: ทดสอบว่าคะแนนสอบเฉลี่ยของนักเรียนในห้องแตกต่างจากเกณฑ์ 70 คะแนนหรือไม่

สมมติฐาน:

- H_0: ค่าเฉลี่ยของประชากร = ค่าที่กำหนด
- H_1: ค่าเฉลี่ยของประชากร ≠ ค่าที่กำหนด (หรืออาจเป็น > หรือ < ก็ได้)
- โรงเรียนอ้างว่านักเรียนมีคะแนนเฉลี่ยวิชาคณิตศาสตร์ 75 คะแนน ครูสงสัยว่าจริงหรือไม่ จึงสุ่มนักเรียน 30 คน พบว่ามีคะแนนเฉลี่ย 72 คะแนน เราจะใช้ One sample t-test เพื่อตรวจสอบว่าแตกต่างจาก 75 อย่างมีนัยสำคัญหรือไม่

One-sample T-test example

การทดสอบเวลาในการทำภารกิจ (Task Completion Time)

- **สถานการณ์**: คุณออกแบบขั้นตอนการสมัครสมาชิกแบบใหม่ และตั้งเกณฑ์มาตรฐานเป้าหมายไว้ว่า “**ผู้ใช้งานควรจะสมัครสมาชิกเสร็จภายใน 60 วินาที**” (เกณฑ์มาตรฐาน $\mu = 60$)
- **การทดสอบ**: นำกลุ่มตัวอย่างผู้ใช้ 30 คนมาทดสอบระบบใหม่ แล้วบันทึกเวลาของทุกคน
- One sample t-test ใช้เมื่อ: เพื่อดูว่า **ค่าเฉลี่ยเวลาของกลุ่มตัวอย่าง** น้อยกว่า 60 วินาทีอย่างมีนัยสำคัญทางสถิติหรือไม่ เพื่อยืนยันว่า UI ใหม่นี้ช่วยให้ผู้ใช้ทำงานได้เร็วขึ้นจริง

One-tailed test แนะนำสำหรับงาน UX/UI เพราะว่าต้องการให้ระบบใหม่ **เร็วกว่าเดิม** (ใช้เวลาน้อยลงกว่าเกณฑ์)

- H_0: ค่าเฉลี่ย**สมัครสมาชิก** >= 60 ดีไซน์ใหม่นี้ยัง*ไม่ผ่านเกณฑ์* หรือไม่ได้ช่วยให้เร็วขึ้นเลย
- H_1: ค่าเฉลี่ย**สมัครสมาชิก** < 60 ดีไซน์ใหม่*ผ่านเกณฑ์* ประสบความสำเร็จในการลดเวลาลงได้จริง

Two-tailed test ดูว่า เวลาเฉลี่ยที่ได้ **ต่างจากเกณฑ์ 60 วินาทีหรือไม่** ไม่สนใจว่ามันจะมากหรือน้อยกว่า

- H_0: ค่าเฉลี่ย**สมัครสมาชิก** = 60
- H_1: ค่าเฉลี่ย**สมัครสมาชิก** ≠ 60

Variable	N	Mean	SD	T-value	df	P-value
ประสิทธิภาพการกรอกสมัครสมาชิก	30	52.40	8.50	-4.903	29	0.001*

	ตัววัด	ค่า
Test value	**เกณฑ์มาตรฐาน** หรือเป้าหมายที่ตั้งไว้	60 วินาที
mean	**ค่าเฉลี่ยจริง** ที่วัดได้จากการทดสอบกับ User	52.40 วินาที (จากกลุ่มทดสอบ 30 คน)
SD	ค่า SD ค่อนข้างกว้าง แปลว่ามีผู้ใช้บางคนทำได้เร็ว (เช่น 58 วินาที) แต่มีบางคนทำช้ามาก ๆ (เช่น เกือบ 90 วินาที) ต้องไปเจาะลึกว่าคนที่ทำช้าเขากำลังติดปัญหาตรงจุดไหน	8.50
T-value	(+) ค่าเฉลี่ยของกลุ่มตัวอย่าง **มากกว่า** ค่ามาตรฐาน (-) ค่าเฉลี่ยของกลุ่มตัวอย่าง **น้อยกว่า** ค่ามาตรฐาน	-4.903
df	ขนาดของกลุ่มตัวอย่าง (sample size หรือ N) ที่เราใช้ทดสอบ (df = n-1, one sample t-test)	29
P-value	**ค่าความน่าจะเป็น** เพื่อดูว่าUI ใหม่นี้ช่วยให้ผู้ใช้ทำงานได้เร็วขึ้นจริง	หาก p < 0.05 แปลว่า UI ใหม่เร็วกว่าเดิมอย่างมีนัยสำคัญ

One-sample T-test example

- **Test value**: คือตัวเลข 60 (เกณฑ์มาตรฐาน $\mu = 60$)
- **Mean**: กลุ่มผู้ทดสอบให้คะแนนเฉลี่ย 52.40 **sec.** (SD=8.50) ซึ่งดูด้วยตาเปล่าพบว่าต่ำกว่าเกณฑ์ 60 คะแนน
- ค่า **p-value**: ค่าที่คำนวณได้คือ 0.001 ซึ่ง **น้อยกว่า** 0.05 หมายความ **เวลาที่ใช้ในระบบใหม่น้อยกว่าค่ามาตรฐานอย่างมีนัยสำคัญทางสถิติ**
- **สรุปผล**:หน้ากรอกสมัครสมาชิกนี้ยัง **ผ่านเกณฑ์** ด้านประสิทธิภาพ (**efficiency**) ที่ทีมงานคาดหวังไว้
- จากการทดสอบประสิทธิภาพการกรอกสมัครสมาชิก โดยตั้งเกณฑ์เป้าหมายไว้ที่ไม่เกิน 60 วินาที พบว่าผู้ใช้งาน ($n=30$) ใช้เวลาเฉลี่ยในการทำภารกิจสำเร็จเท่ากับ 52.40 วินาที (SD=8.50) ซึ่งต่ำกว่าเกณฑ์ที่กำหนดไว้อย่างมีนัยสำคัญทางสถิติที่ระดับ .05
- $t(29) = -4.903$, $p = 0.001$ สรุปได้ว่าขั้นตอนการสมัครสมาชิกแบบใหม่ช่วยประหยัดเวลาและทำงานได้รวดเร็วขึ้นกว่าค่ามาตรฐานเดิมอย่างมีนัยสำคัญ

Independent Samples T-test

❑ Independent samples t-test ใช้เมื่อ: เปรียบเทียบค่าเฉลี่ยของข้อมูล 2 **กลุ่มที่เป็นอิสระจากกัน** (คนละกลุ่มกัน)

- **ตัวอย่าง**: เปรียบเทียบคะแนนสอบระหว่างนักเรียนห้อง A และห้อง B
- เปรียบเทียบเวลาในการใช้งานระหว่างนักเรียนชายกับนักเรียนหญิง
- เปรียบเทียบเวลาในการใช้งานแอพพลิเคชั่น layout A and B
- เปรียบเทียบการใช้งานระหว่าง Gen X and Y

- สมมติฐาน:
- H_0: ค่าเฉลี่ยของประชากรกลุ่มที่ 1 = ค่าเฉลี่ยของประชากรกลุ่มที่ 2
- H_1: ค่าเฉลี่ยของประชากรกลุ่มที่ 1 ≠ ค่าเฉลี่ยของประชากรกลุ่มที่ 2

Independent Samples T-test Example

- **ตัวอย่าง**: สมมติว่าเราทำ A/B testing การเปรียบเทียบ เวลาในการทำการจองตั๋วภาพยนตร์ ระหว่างดีไซน์แอปพลิเคชันแบบเดิม (Group A: control) กับดีไซน์แอปพลิเคชันแบบใหม่ที่ปรับปรุง UX/UI แล้ว (Group B: experiment) โดยวัดเวลาเป็นวินาที
- กลุ่มที่ 1 **Group A - ดีไซน์เดิม**
- กลุ่มที่ 2 **Group B - ดีไซน์ใหม่**
- **ตัวแปรตาม** (dependent variable): เวลาที่ใช้ในการทำรายการจนสำเร็จ (หน่วย: วินาที)

สมมติฐาน

- $H_0: \mu_1 = \mu_2$ เวลาเฉลี่ยในการใช้งานของทั้งสองดีไซน์ไม่แตกต่างกัน
- $H_1: \mu_1 \neq \mu_2$ เวลาเฉลี่ยในการใช้งานของทั้งสองดีไซน์แตกต่างกัน

Group	N	Mean	SD	T-value	df	P-value
A	30	45.50	6.20	9.42	58	0.001*
B	30	32.10	4.50			

- จากการทดสอบ independent sample t-test เพื่อเปรียบเทียบเวลาเฉลี่ยในการจองตั๋วภาพยนตร์ระหว่างผู้ใช้งานกลุ่มที่ใช้ดีไซน์เดิม ($\bar{X}$ = 45.50, SD = 6.20) และกลุ่มที่ใช้ดีไซน์ใหม่ ($\bar{X}$ = 32.10, SD = 4.80)
- พบว่าค่า p-value มีค่าน้อยกว่า 0.001 ซึ่งน้อยกว่าระดับนัยสำคัญทางสถิติ 0.05 จึง**ปฏิเสธสมมติฐานหลัก $H_0: \mu_1 = \mu_2$ และยอมรับสมมติฐานทางเลือก $H_1: \mu_1 \neq \mu_2$**
- **สรุปความหมายเชิง UX/UI:** ดีไซน์แอปพลิเคชันแบบใหม่ช่วยลดเวลาในการทำธุรกรรมจองตั๋วภาพยนตร์ได้เร็วกว่าดีไซน์แบบเดิมอย่างมีนัยสำคัญทางสถิติ โดยผู้ใช้ใช้เวลาน้อยลงเฉลี่ย 13.4 วินาที ซึ่งยืนยันว่าการปรับปรุง UX/UI ครั้งนี้เพิ่มประสิทธิภาพการใช้งาน (efficiency) ได้จริง

Paired/Dependent samples T-test

❑ Paired หรือ dependent samples t-test ใช้เมื่อ : เปรียบเทียบค่าเฉลี่ยของกลุ่มตัวอย่าง **กลุ่มเดียวกัน** แต่มีการเก็บข้อมูล 2 **ครั้ง เช่น** ในสองสถานการณ์ หรือสองช่วงเวลา

- **ตัวอย่าง**: เปรียบเทียบคะแนนสอบ Pre-test และ Post-test ของนักเรียนกลุ่มเดิม
- เปรียบเทียบการใช้งานซอฟแวร์ ก่อนเทรน และ หลังเทรน

สมมติฐาน:

- H_0: ค่าเฉลี่ยของผลต่างระหว่างคู่ข้อมูล = 0
- H_1: ค่าเฉลี่ยของผลต่างระหว่างคู่ข้อมูล ≠ 0

Dependent samples T-test example

- ทีม UX/UI ต้องการปรับปรุง **หน้ากรอกข้อมูลชำระเงิน** (checkout page) ของแอปพลิเคชันช้อปปิ้งออนไลน์ เนื่องจากเดิมมีขั้นตอนที่ซับซ้อน ทำให้ผู้ใช้ใช้เวลานานและมีอัตราการละทิ้งตะกร้าสินค้าสูง
- ทีมงานจึงได้ออกแบบหน้า checkout แบบใหม่ (ลดจำนวนฟิลด์ลงและใช้การกรอกอัตโนมัติ) จากนั้นทำการทดสอบกับ **ผู้ใช้กลุ่มเดิมจำนวน** 10 **คน** โดยวัด **เวลาที่ใช้ในการชำระเงินสำเร็จ** (**หน่วย**: **วินาที**) ทั้งในระบบดีไซน์เดิม (Pre-test) และดีไซน์ใหม่ (Post-test)

Dependent samples T-test example

UserID	Pre-test-A	Post-test-B	Difference
1	45	32	-13
2	50	35	-15
3	38	30	-8
4	42	28	-14
5	55	40	-15
6	48	33	-15
7	36	31	-5
8	52	37	-15
9	47	34	-13
10	43	29	-14

	mean	SD	t	df	p
A	45.60	5.95	-11.13	9	0.001
B	33.90	3.73			

- **หน้า checkout ดีไซน์ใหม่ช่วยให้ผู้ใช้ชำระเงินได้เร็วขึ้นกว่าดีไซน์เดิมอย่างมีนัยสำคัญทางสถิติ**
- **ความเร็วที่เพิ่มขึ้น**: ค่าเฉลี่ยเวลาของดีไซน์ใหม่ลดลงเหลือ 33.90 **วินาที** จากเดิม 45.60 **วินาที** (ลดลงโดยเฉลี่ย 11.7 วินาที หรือเร็วขึ้นประมาณ 25%)
- **นัยสำคัญทางสถิติ**: ค่า **p-value มีค่าน้อยกว่า** 0.001 ซึ่งต่ำกว่าเกณฑ์นัยสำคัญปกติที่ 0.05 (และค่า **t = -**11.13) แสดงว่าการลดลงของเวลาไม่ได้เกิดจากความบังเอิญ
- ผลลัพธ์นี้ยืนยันว่าโครงสร้างหน้า checkout ใหม่ประสบความสำเร็จในการลดความยุ่งยาก ของผู้ใช้ สามารถนำดีไซน์ใหม่นี้ขึ้นระบบจริง เพื่อช่วยเพิ่มอัตราการซื้อสำเร็จ

ANOVA (F-test)

- วิธีการทางสถิติที่ใช้เปรียบเทียบค่าเฉลี่ยของกลุ่มตัวอย่างตั้งแต่ 3 กลุ่มขึ้นไป ว่ามีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติหรือไม่
- เช่น ออกแบบปุ่ม CTA มา 3 สี คือ **สีแดง สีเขียว และสีน้ำเงิน** และต้องการดูว่าสีไหนให้ผลลัพธ์ดีที่สุด
- เลือกใช้งาน function 3 แบบ (menu, icon, keyboard shortcut) ว่าแบบไหนทำให้ผู้ใช้ใช้เวลาสั้นที่สุดที่สุด
- ทดสอบว่าระบบทะเบียนขอฝมหาวิทยาลัยว่าได้คะแนนความง่ายในการใช้งาน แตกต่างกันไหมระหว่างกลุ่ม **นักเรียน, อาจารย์, และเจ้าหน้าที่**

ANOVA (F-test) example

- ทดสอบว่า รูปแบบของพื้นหลัง (background) ที่แตกต่างกัน 3 แบบ (default, preferred image, static color) ส่งผลต่อเวลาที่ผู้ใช้ใช้ในการทำภารกิจบนเว็บไซต์ (task completion time) แตกต่างกันอย่างมีนัยสำคัญหรือไม่
- **เป้าหมาย**: ต้องการหาว่าพื้นหลังแบบไหนที่ช่วยให้ผู้ใช้โฟกัสและทำภารกิจ ได้เร็วที่สุด
- **ตัวแปรต้น** (independent variable): รูปแบบ background 3 แบบ ได้แก่
  - default (พื้นหลังสีขาว/เทามาตรฐาน)
  - preferred image (ภาพถ่ายวิวทิวทัศน์ที่ผู้ใช้มักจะชอบ)
  - static color (สีโทนเย็นแบบคงที่ เช่น สีฟ้าอ่อนหรือเขียวอ่อน)
- **ตัวแปรตาม** (dependent variable): เวลาที่ใช้ในการทำภารกิจเสร็จสิ้น (หน่วย: วินาที)
- สมมติฐาน
- H_0 (สมมติฐานหลัก): พื้นหลังทั้ง 3 แบบ ให้ความเร็วในการทำภารกิจ**ไม่แตกต่างกัน**
- H_1 (สมมติฐานทางเลือก): มีพื้นหลังอย่างน้อย 1 แบบ ที่ให้ความเร็วในการทำภารกิจ**แตกต่างจากแบบอื่น**

ANOVA (F-test) example

Source of variation	Sum of square	df	Mean	F-value	P-value	F-test
Between groups	125.40	2	62.70	6.43	0.0053	3.35
Within groups	263.25	27	9.75			
Total	388.65	29				

Between groups ความแตกต่างระหว่าง **"ค่าเฉลี่ยของแต่ละกลุ่ม"** ว่าห่างกันมากน้อยแค่ไหน

- เป็นการดูว่า กลุ่มที่ใช้ default, กลุ่มที่ใช้ prefer image และกลุ่มที่ใช้ static color มีค่าเฉลี่ยเวลาที่ใช้ทำต่างกันอย่างมากหรือไม่
- ยิ่ง Between groups มีค่า**สูง** แปลว่า รูปแบบพื้นหลังที่ต่างกัน ส่งผลต่อพฤติกรรมของผู้ใช้อย่างชัดเจน

Within groups **(ความแปรปรวนภายในกลุ่ม หรือ error)**

- ความแตกต่างของข้อมูล "ภายในกลุ่มเดียวกันเอง" (คนกลุ่มเดียวกัน เจอพื้นหลังแบบเดียวกัน แต่ละคนก็ยังใช้เวลาไม่เท่ากัน)
- ในกลุ่มที่ใช้พื้นหลังแบบ default เหมือนกันทั้ง 10 คน นาย A อาจจะคลิกเร็วมาก (2 วินาที) แต่นาย B อาจจะตาฝ้าฟางหรือเน็ตช้า (8 วินาที) ความต่างตรงนี้ไม่ได้เกิดจากพื้นหลัง แต่เกิดจากทักษะส่วนตัว อายุ หรือสภาพแวดล้อมของตัวผู้ใช้เอง
- ยิ่งค่า Within groups มีค่า**ต่ำ** แปลว่าผู้ใช้ในกลุ่มเดียวกันมีพฤติกรรมเสถียรคล้ายๆ กัน ไม่ได้มีปัจจัยภายนอกมารบกวน

ANOVA (F-test) example

Source of variation	Sum of square	df	Mean	F-value	P-value	F-critical
Between groups	125.40	2	62.70	6.43	0.0053	3.35
Within groups	263.25	27	9.75			
Total	388.65	29				

- การที่ค่า **F ที่คำนวณได้** (6.43) **มีค่ามากกว่า F critical** (3.35) หมายความว่า ผลลัพธ์ความแตกต่างที่เกิดขึ้นในการทดลองนี้ มีนัยสำคัญทางสถิติ (statically significant)
- รูปแบบของพื้นหลัง (background) ที่แตกต่างกัน ส่งผลต่อเวลาในการทำภารกิจของผู้ใช้**แตกต่างกันอย่างแท้จริง**
- *"มีอย่างน้อย 1 คู่ที่ต่างกัน"* แต่ยังไม่ได้บอกว่าคู่ไหน จำเป็นต้องนำข้อมูลไปทดสอบต่อด้วย post-hoc test เพื่อเจาะลึกว่าพื้นหลังแบบไหนดีที่สุดและแย่ที่สุดอย่างชัดเจน

ANOVA (F-test) example

Source of variation	Sum of square	df	Mean	F-value	P-value	F-critical
Between groups	125.40	2	62.70	6.43	0.0053	3.35
Within groups	263.25	27	9.75			
Total	388.65	29				

F-value	F-critical
ค่าสถิติที่คำนวณมาจาก**ข้อมูลดิบในการทดลองของเราจริง ๆ**	**เกณฑ์ขั้นต่ำ**ที่กำหนดโตามตารางมาตรฐาน เพื่อเปรียบเทียบกับ F-value
คำนวณจากสูตร ANOVA	จากตารางสถิติ (F-table) โดยดูจาก **จำนวนกลุ่ม**, **จำนวนผู้ทดสอบทั้งหมด**, และ**ระดับนัยสำคัญ**
เปลี่ยนไปตามพฤติกรรมของผู้ใช้จริง	**คงที่เสมอ**ตราบใดที่จำนวนกลุ่มและจำนวนผู้ทดสอบในการวางแผนการทดลองยังเท่าเดิม

ANOVA (F-test) example (Post-hoc)

Comparison pairs	mean	HSD (>2.15)	P-value	Conclusion
Default vs Prefer	3.10	yes	0.012	ต่างกันแบบมีนัยสำคัญ
Default vs Static	1.30	no	0.380	ไม่ต่างกันแบบมีนัยสำคัญ
Static vs Prefer	4.40	yes	0.002	ต่างกันแบบมีนัยสำคัญ

- สมมุติผลคำนวณค่าเฉลี่ยเวลา ของแต่ละกลุ่ม:
- จากการคำนวณเปรียบเทียบทีละคู่ (กำหนดค่าวิกฤต HSD = 2.15 วินาที):
- **static**: เฉลี่ย 4.2 **วินาที** (เร็วที่สุด)
- **default**: เฉลี่ย 5.5 **วินาที**
- **prefer**: เฉลี่ย 8.6 **วินาที** (ช้าที่สุด)

- **prefer คือตัวปัญหา** :เมื่อนำ ไปเทียบกับ default (ต่างกัน 3.10 วินาที) และ static (ต่างกัน 4.40 วินาที) พบว่า**มีความแตกต่างอย่างมีนัยสำคัญทั้งสองคู่**

One-way ANOVA vs Two-way ANOVA

One-way ANOVA	Two-way ANOVA
ทดสอบ 1 **องค์ประกอบดีไซน์** (ที่มีให้เลือกทดสอบตั้งแต่ 3 รูปแบบขึ้นไป)	ทดสอบ 2 **องค์ประกอบดีไซน์พร้อมกัน** (เพื่อดูการจับคู่และผลกระทบร่วมกัน)
Independent variable = 1	Independent variable = 2
dependent variable : time, accuracy	dependent variable : time, accuracy
หาค่าเฉลี่ยเพื่อดู **ความต่างโดยรวม** ของรูปแบบดีไซน์ที่ส่งผลต่อผู้ใช้	หา Interaction effect (ดูว่าปัจจัยที่ 1 ส่งผลต่อปัจจัยที่ 2 หรือไม่
เช่น abstract icon, concrete icon, combination icon	เช่น independent variable 1 = abstract icon, concrete icon independent variable 2 = background (white, black)

One-way ANOVA vs Two-way ANOVA

Case	ANOVA
เปรียบเทียบแค่สีปุ่ม 3 สี (แดง, เขียว, น้ำเงิน) เพื่อดูเวลาเฉลี่ยที่คนหาปุ่มเจอ	One-way ANOVA
เปรียบเทียบ layout 4 แบบ เพื่อดูว่าแบบไหนทำให้อยู่บนหน้าเว็บนานที่สุด	One-way ANOVA
เปรียบเทียบ ขนาดฟอนต์ (เล็ก/ใหญ่) x สีฟอนต์ (ดำ/เทา) เพื่อดูความเร็วในการอ่าน	Two-way ANOVA
เปรียบเทียบ ตำแหน่งปุ่ม (บน/ล่าง) x ประเภทอุปกรณ์ (มือถือ/คอม) เพื่อดูอัตราการกด	Two-way ANOVA

ANOVA – Two-way ANOVA example

- สถิติที่ใช้ทดสอบความแตกต่างของค่าเฉลี่ยระหว่างกลุ่ม เมื่อมี ตัวแปรอิสระ 2 ตัว และ ตัวแปรตาม 1 ตัว
- สมมติว่าทีม UX/UIต้องการดูว่า **ประเภทของไอคอน** และ **สีของพื้นหลัง** ส่งผลต่อ **ความเร็วในการค้นหาไอคอน** (response time) ของผู้ใช้ต่างกันอย่างไร และตัวแปรทั้งสองนี้มีอิทธิพลร่วมกันหรือไม่

ตัวแปรในการทดสอบ (factors)

- factors A: abstract icon vs concrete icon
- factors B: black background vs white background
- **ตัวแปรตาม** (dependent variable): response time (sec)

ANOVA – Two-way ANOVA example

- สถิติที่ใช้ทดสอบความแตกต่างของค่าเฉลี่ยระหว่างกลุ่ม เมื่อมี ตัวแปรอิสระ 2 ตัว และ ตัวแปรตาม 1 ตัว
- สมมติว่าทีม UX/UIต้องการดูว่า **ประเภทของไอคอน** และ **สีของพื้นหลัง** ส่งผลต่อ **ความเร็วในการค้นหาไอคอน** (response time) ของผู้ใช้ต่างกันอย่างไร และตัวแปรทั้งสองนี้มีอิทธิพลร่วมกันหรือไม่

ตัวแปรในการทดสอบ (factors)

- factors A: abstract icon vs concrete icon
- factors B**:** black background vs white background
- **ตัวแปรตาม** (dependent variable): response time (sec)
- abstract x black; abstract x white; concrete x black; concrete x white;
- สมมติว่าเราเกณฑ์กลุ่มตัวอย่างมาทดสอบทั้งหมด 20 คน (แบ่งกลุ่มละ 5 คน สุ่มเจอ 1 ใน 4 เงื่อนไข) และนี่คือความเร็วที่พวกเขาทำได้:

Response time

	Abstract	concrete
Black	4.2	2.1
	4.8	2.5
	3.9	1.9
	4.5	2.3
	4.1	2.2
White	3.5	2.8
	3.8	3.0
	3.2	2.6
	3.6	2.9
	3.4	2.7

Background	Icon type	N	Mean	SD
Black	Abstract	5	4.30	0.35
	Concrete	5	2.20	0.22
White	Abstract	5	3.50	0.22
	Concrete	5	2.80	0.16
Total			3.20	0.82

Source	SS	df	Mean	F-value	P-value	
background	0.050	1	0.050	0.80	0.384	Non sig
Icon type	9.800	1	9.800	156.80	0.001*	Sig
Background x icon	2.450	1	2.450	39.20	0.001*	Sig
error	1.000	16	0.0625			
total	13.300	19				

ANOVA – Two-way ANOVA example

- **ดูค่า p-value ของ background (= 0.384)**:เนื่องจากค่ามากกว่า 0.05 หมายความว่า **สีพื้นหลังเพียงอย่างเดียวไม่ได้ทำให้ความเร็วของผู้ใช้ต่างกัน** (ถ้าเราจับไอคอนทุกแบบมารวมกัน แล้วเทียบแค่ ดำ **VS** ขาว เวลาเฉลี่ยจะพอ ๆ กันคือ 3.25 วินาที กับ 3.15 วินาที)
- **ดูค่า p-value ของ icon type (< 0.001)**:ค่านี้น้อยกว่า 0.05 อย่างมาก แสดงว่า **ประเภทของไอคอนมีผลต่อความเร็วอย่างรุนแรง** และเมื่อดูควบคู่กับค่าเฉลี่ยในตารางแรก จะเห็นว่าผู้ใช้หา concrete icon **(เฉลี่ยรวม 2.50 วินาที) ได้เร็วกว่า** abstract icon **(เฉลี่ยรวม 3.90 วินาที) เสมอ**
- **ดูค่า p-value ของ background x icon (< 0.001)**:ค่านี้น้อยกว่า 0.05 แสดงว่า **อย่างมีนัยสำคัญ**
- มันแปลว่า **"ผลของประเภทไอคอนจะเปลี่ยนไปตามสีพื้นหลังที่มันอยู่"** โดยถ้าอยู่บนพื้นหลังสีดำ concrete icon จะช่วยให้ทำเวลาได้เร็วขึ้นแบบก้าวกระโดด (เร็วขึ้นถึง 2.1 วินาที) แต่ถ้าอยู่บนพื้นหลังสีขาว แม้ concrete icon จะเร็วกว่า แต่ก็เร็วกว่าเพียงเล็กน้อยเท่านั้น (เร็วขึ้นแค่ 0.7 วินาที)

Source	mean	SD	F-value	P-value	
Icon type			156.80	0.001*	concrete เร็วกว่า abstract ชัดเจน
* abstract	3.90	0.49			
* concrete	2.50	0.36			
Background					
* black	3.25	1.14			เวลาเฉลี่ยภาพรวมพอ ๆ กับสีขาว
* white	3.15	0.44			เวลาเฉลี่ยภาพรวมพอ ๆ กับสีดำ
Interaction X					
* blackXabstrt	4.30	0.35			**แย่ที่สุด** ผู้ใช้ใช้เวลานานที่สุด
* blackXconcrt	2.20	0.22			**ดีที่สุด** ผู้ใช้ค้นพบและคลิกได้เร็วที่สุ
* whiteXabstrt	3.50	0.22			ความเร็วปานกลาง
* whiteXconcrt	2.80	0.16			ความเร็วดีปานกลาง

ANOVA – Two-way ANOVA example

- **ห้ามใช้** abstract icon **บน** dark mode **เด็ดขาด**: จากค่าเฉลี่ย 4.30 **วินาที** (แย่ที่สุด) ผู้ใช้งานหาไอคอนไม่เจอหรือใช้เวลานานในการหา

- concrete icon **คือทางเลือกที่ดีที่สุด**: ไม่ว่าจะอยู่บนพื้นหลังขาวหรือดำ ไอคอน ทำเวลาได้ดีกว่าเสมอ (เฉลี่ยรวม 2.50 **วินาที**)

- **ออกแบบ** dark mode **ต้องเน้น** concrete icon **เท่านั้น**: หากแอปพลิเคชันของคุณจำเป็นต้องมี dark mode (black background) การใช้ concrete icon จะช่วยให้ผู้ใช้ทำงานได้เร็วที่สุดแบบก้าวกระโดด (2.20 **วินาที**) เนื่องจากรูปทรงที่คุ้นตาช่วยชลดความยากในการมองเห็นบนพื้นหลังมืดได้ดี

Repeated Measures

- วิธีการเก็บข้อมูลจากกลุ่มตัวอย่างชุดเดิมซ้ำๆ หลายครั้ง ภายใต้เวลาหรือเงื่อนไขที่ต่างกัน
- **กลุ่มเดิมทั้งหมด**: ใช้คนหรือหน่วยตัวอย่างเดิมในการทดลองทุกครั้ง
- **เปรียบเทียบเวลา/เงื่อนไข**: ดูการเปลี่ยนแปลงที่เกิดขึ้น เช่น ก่อนทำ หลังทำ และติดตามผล
- **ลดความแปรปรวน**: ช่วยตัดปัญหาความแตกต่างระหว่างบุคคลออกไป ทำให้ผลลัพธ์แม่นยำขึ้น
- **ข้อดี**: ใช้จำนวนคนน้อยลง และควบคุมความแตกต่างระหว่างบุคคลได้ดี
- **ข้อเสีย**: อาจเกิดความล้าจากการทดสอบซ้ำ หรือผู้เข้าร่วมการทดลองลาออกกลางคัน

Repeated Measures ANOVA

- วิธีการเก็บข้อมูลจากกลุ่มตัวอย่างชุดเดิมซ้ำๆ หลายครั้ง ภายใต้เวลาหรือเงื่อนไขที่ต่างกัน
- **กลุ่มเดิมทั้งหมด**: ใช้คนหรือหน่วยตัวอย่างเดิมในการทดลองทุกครั้ง
- **เปรียบเทียบเวลา/เงื่อนไข**: ดูการเปลี่ยนแปลงที่เกิดขึ้น เช่น ก่อนทำ หลังทำ และติดตามผล
- **ลดความแปรปรวน**: ช่วยตัดปัญหาความแตกต่างระหว่างบุคคลออกไป ทำให้ผลลัพธ์แม่นยำขึ้น
- **ข้อดี**: ใช้จำนวนคนน้อยลง และควบคุมความแตกต่างระหว่างบุคคลได้ดี
- **ข้อเสีย**: อาจเกิดความล้าจากการทดสอบซ้ำ หรือผู้เข้าร่วมการทดลองลาออกกลางคัน

Repeated Measures ANOVA

- วิธีการเก็บข้อมูลจากกลุ่มตัวอย่างชุดเดิมซ้ำๆ หลายครั้ง ภายใต้เวลาหรือเงื่อนไขที่ต่างกัน
- **กลุ่มเดิมทั้งหมด**: ใช้คนหรือหน่วยตัวอย่างเดิมในการทดลองทุกครั้ง
- **เปรียบเทียบเวลา/เงื่อนไข**: ดูการเปลี่ยนแปลงที่เกิดขึ้น เช่น ก่อนทำ หลังทำ และติดตามผล
- **ลดความแปรปรวน**: ช่วยตัดปัญหาความแตกต่างระหว่างบุคคลออกไป ทำให้ผลลัพธ์แม่นยำขึ้น
- **ข้อดี**: ใช้จำนวนคนน้อยลง และควบคุมความแตกต่างระหว่างบุคคลได้ดี
- **ข้อเสีย**: อาจเกิดความล้าจากการทดสอบซ้ำ หรือผู้เข้าร่วมการทดลองลาออกกลางคัน
- ตัวอย่าง การทดสอบขนาดของไอคอน 16x16 32x32 48x48 64x64 pixels ขนาดไหนใช้เร็วสุด กลุ่มตัวอย่าง 10 คน

Participant	16x16	32x32	48x48	64x64
1	3.5	2.1	1.8	1.7
2	4.2	2.5	1.9	1.8
3	3.8	2.2	1.7	1.6
4	3.9	2.4	2.0	1.9
5	4.5	2.8	2.1	2.0
6	3.6	2.0	1.6	1.5
7	4.0	2.3	1.9	1.9
8	3.7	2.1	1.8	1.7
9	4.4	2.6	2.2	2.1
10	4.1	2.4	2.0	1.8
Mean	3.97	2.34	1.90	1.80
SD	0.32	0.25	0.18	0.18

Test within-Subjects Effects

- **นี่คือตารางที่สำคัญที่สุด** ใช้ดูว่าขนาดไอคอนที่ต่างกัน ส่งผลต่อเวลาอย่างมีนัยสำคัญหรือไม่

source	Mean	df	F	Sig.	Partial Eta squared
Icon size	10.417	3	184.50	0.001*	0.954

- ดูช่อง F และ sig. จะพบว่า ค่า sig < .001 (น้อยกว่า 0.05) แสดงว่า **ขนาดของไอคอนที่ต่างกัน มีผลทำให้เวลาที่ใช้แตกต่างกันอย่างมีนัยสำคัญทางสถิติ**
- และค่า partial Eta squared (0.954) บอกว่าขนาดไอคอนส่งผลต่อความเร็วสูงมากถึง 95.4%

Size (I)	Size (J)	mean	Std error	Sig.
16x16	32x32	1.630*	0.112	<0.001
	48x48	2.070*	0.104	<0.001
	64x64	2.170*	0.111	<0.001
32x32	48x48	0.440*	0.045	<0.001
	64x64	0.540*	0.052	<0.001
48x48	64x64	0.100	0.039	0.198

- คู่ที่มีเครื่องหมาย * หรือค่า **sig**. < 0.05 แปลว่าขนาดคู่นั้นทำเวลาได้ต่างกันจริง ส่วนคู่ 48**X**48 **VS** 64**X**64 **มีค่า sig**. = 0.198 (**มากกว่า** 0.05) แสดงว่าสองขนาดนี้ทำเวลาได้เร็วพอๆ กัน ไม่ต่างกันอย่างมีนัยสำคัญ

Result

- ผลการวิเคราะห์พบว่า **ขนาดของไอคอนที่แตกต่างกัน ส่งผลต่อเวลาที่ใช้ในการค้นหาและคลิกไอคอนอย่างมีนัยสำคัญทางสถิติ** ที่ระดับ .05, $F(3, 27) = 184.50$, $p < .001$ โดยมีค่า partial $\eta^2 = 0.954$ ซึ่งแสดงว่า ขนาดของไอคอนสามารถอธิบายความผันแปรของเวลาที่ใช้ได้ถึงร้อยละ 95.4
- **ขนาด 16X16** ($M = 3.97$, $SD = 0.32$) ใช้เวลาในการคลิก**นานที่สุด** ซึ่งแตกต่างจากขนาด 32X32, 48X48 และ 64X64 อย่างมีนัยสำคัญทางสถิติ ($p < .001$ ทุกคู่)
- **ขนาด 32X32** ($M = 2.34$, $SD = 0.25$) ใช้เวลา**ลดลง**อย่างมีนัยสำคัญทางสถิติเมื่อเทียบกับขนาด 16X16 ($p < .001$) แต่ยังคงใช้เวลามากกว่าขนาด 48X48 และ 64X64 อย่างมีนัยสำคัญทางสถิติ ($p < .001$)
- **ขนาด 48X48** ($M = 1.90$, $SD = 0.18$) ใช้เวลา**เร็วกว่า**ขนาด 32X32 อย่างมีนัยสำคัญทางสถิติ ($p < .001$)
- **ขนาด 64X64** ($M = 1.80$, $SD = 0.18$) ทำเวลาได้ดีที่สุด แต่เมื่อนำไปเปรียบเทียบกับขนาด 48X48 พบว่า **เวลาที่ใช้ไม่แตกต่างกันอย่างมีนัยสำคัญทางสถิติ** ($p = .198$)

Discussion

- ผลการทดลองนี้ชี้ให้เห็นว่าการเพิ่มขนาดไอคอนจาก 16X16 ไปจนถึง 48X48 ช่วยเพิ่มประสิทธิภาพการใช้งาน (usability) ของผู้ใช้อย่างก้าวกระโดดเนื่องจากเป้าหมายมีขนาดใหญ่ขึ้นตามกฎของฟิตส์ (Fitts's Law)
- **ขนาด 48X48 ถือเป็นขนาดที่เหมาะสมที่สุดของการออกแบบ**
- เนื่องจากเมื่อขยายขนาดไอคอนเพิ่มขึ้นไปเป็น 64X64 ประสิทธิภาพความเร็วของผู้ใช้ไม่ได้เพิ่มขึ้นอย่างมีนัยสำคัญ ในทางปฏิบัติจึง **ควรเลือกใช้ไอคอนขนาด 48X48 เป็นมาตรฐาน** เพื่อให้ผู้ใช้ได้รับประสบการณ์การใช้งานที่ดีที่สุดโดยไม่สูญเสียพื้นที่บนหน้าจอ ไปโดยเปล่าประโยชน์

Chi-square test

- เครื่องมือทางสถิติที่ใช้ตรวจสอบว่า 2 ตัวแปรมีความสัมพันธ์กันหรือส่งผลต่อกันจริงหรือไม่
- เพื่อเปรียบเทียบว่า **"พฤติกรรมของผู้ใช้หรือผลลัพธ์ที่เกิดขึ้นจริง" แตกต่างจาก "สิ่งที่คาดหวังไว้"** อย่างมีนัยสำคัญทางสถิติหรือไม่
- เช่น ทีม UX/UI ต้องการทดสอบว่า **สีของปุ่มตกลงซื้อสินค้า** ระหว่าง **สีเขียว** (A) กับ **สีแดง** (B) ส่งผลต่อ **อัตราการคลิกซื้อสินค้า** แต่างกันหรือไม่ โดยเก็บข้อมูลจากผู้ใช้งานทั้งหมด 400 คน (แบ่งกลุ่มละ 200 คนเท่ากัน)

Design	Click	No click	Total
Green - A	65	135	200
Red - B	35	165	200
Total	100	300	400

- H_0 (สมมติฐานหลัก): สีเขียวและสีแดงให้ผลลัพธ์ไม่ต่างกัน
- H_1 (สมมติฐานทางเลือก): สีของปุ่ม (เขียว **vs** แดง) ส่งผลต่อการคลิกซื้อแตกต่างกัน

Expected Value Table

- ในกรณีที่สีของปุ่มไม่มีผล

Design	Click	No click	Total
Green - A	50	150	200
Red - B	50	150	200
Total	100	300	400

Statistic	Value	df	P-value
Pearson Chi-Square	12.00	1	<0.001
N	400	-	-

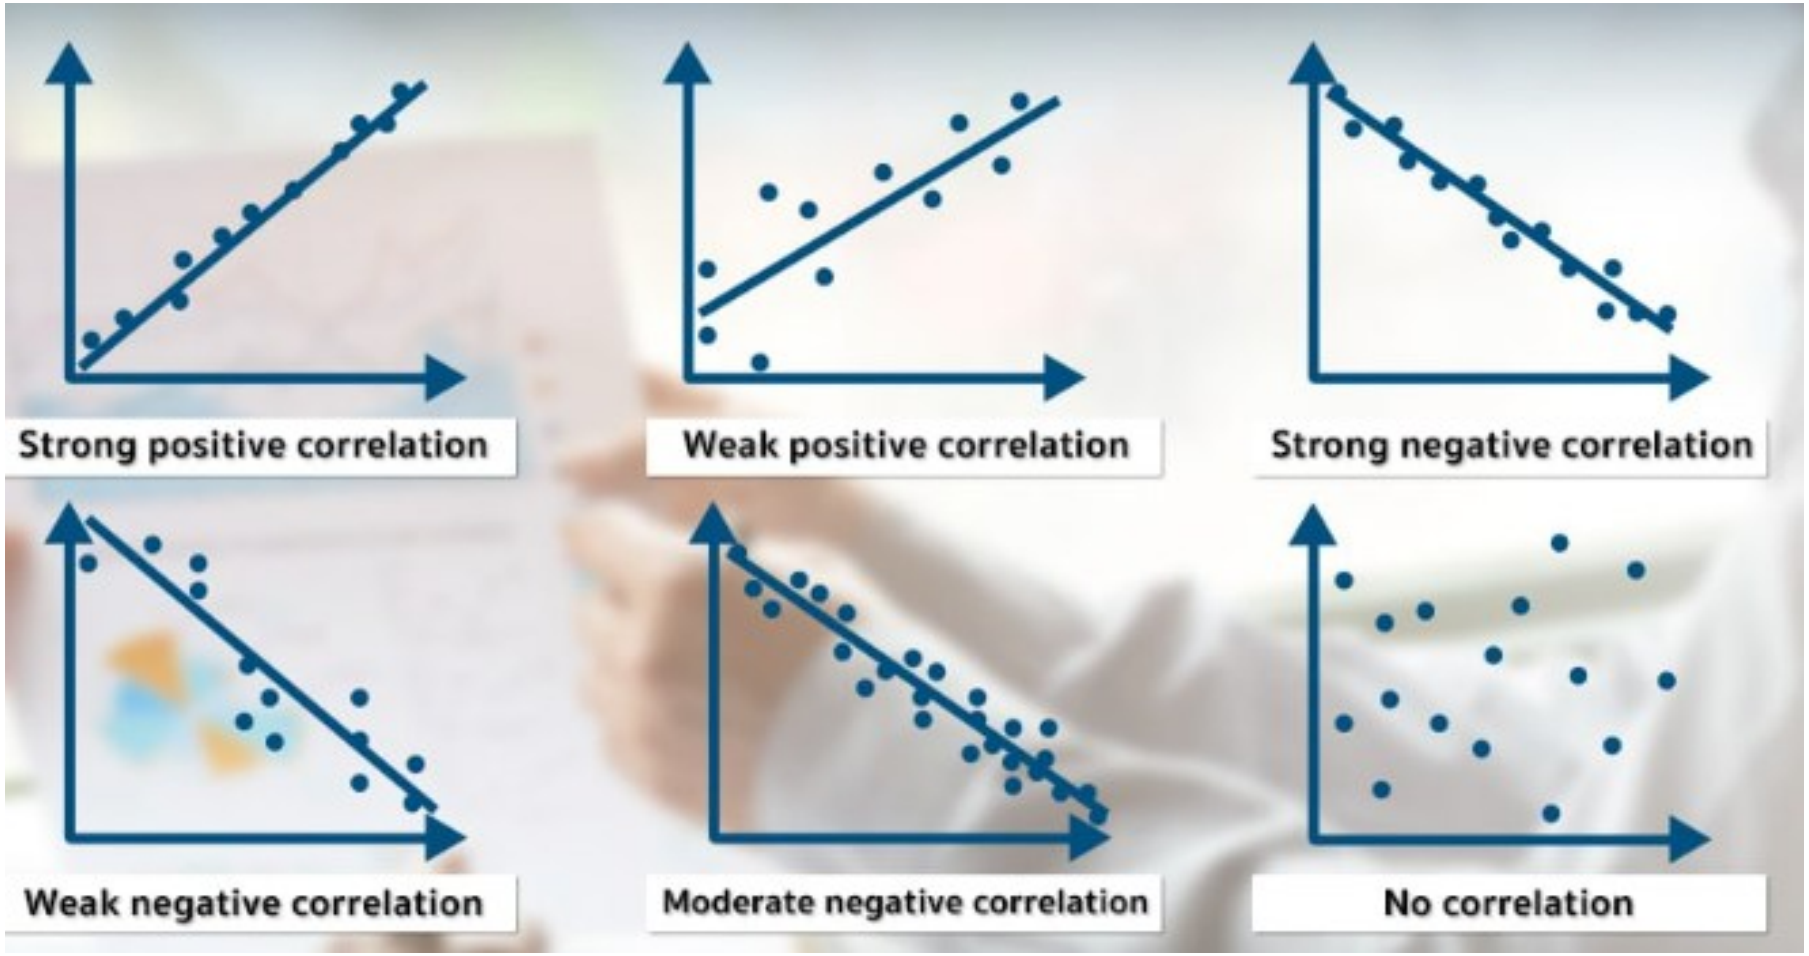
- ระบบนี้ ทีม UX/UI ควรเลือกใช้ **ปุ่มสีเขียว** เนื่องจากให้ประสิทธิภาพ ดีกว่าปุ่มสีแดงเกือบเท่าตัว

- p-value น้อยกว่า 0.001 หมายความว่า สีของปุ่ม (เขียว vs แดง)ส่งผลต่อพฤติกรรมการคลิกซื้อของผู้ใช้อย่างมีนัยสำคัญยิ่งทางสถิติ
- **ปุ่มสีเขียว** มีอัตราการคลิกสูงถึง **32.5%** (65 จาก 200 คน) ในขณะที่ **ปุ่มสีแดง** มีอัตราการคลิกเพียง **17.5%** (35 จาก 200 คน)

Correlation

- เครื่องมือที่ใช้วัดระดับความสัมพันธ์ระหว่างตัวแปรตั้งแต่ 2 ตัวขึ้นไป ว่ามีความเกี่ยวข้องกันมากน้อยแค่ไหน และเปลี่ยนแปลงไปในทิศทางเดียวกันหรือตรงกันข้าม
- มีค่าอยู่ระหว่าง -1.0 **ถึง** +1.0
- **ค่าเข้าใกล้** +1.0 (Positive correlation): มีความสัมพันธ์เชิงบวก เมื่อตัวแปรหนึ่งเพิ่มขึ้น อีกตัวก็เพิ่มขึ้นตาม เช่น ยิ่งอ่านหนังสือมาก คะแนนสอบก็ยิ่งสูง
- **ค่าเข้าใกล้** -1.0 (negative correlation): มีความสัมพันธ์เชิงลบ เมื่อตัวแปรหนึ่งเพิ่มขึ้น อีกตัวจะลดลง เช่น ขับรถเร็วขึ้น ระยะเวลาในการเดินทางก็ยิ่งน้อยลง
- **ค่าเท่ากับ** 0 (zero correlation): ไม่มีความสัมพันธ์กันเลย การเปลี่ยนแปลงของตัวแปรหนึ่งไม่มีผลอะไรกับอีกตัวแปรหนึ่ง
- Pearson กับ Spearman

Correlation



Pearson vs Spearman Correlation

- Pearson
- เหมาะกับข้อมูลเชิงปริมาณ
- Ratio
- Linear relationship
- ไม่มีค่า outliers มากเกินไป

- Spearman
- เหมาะกับข้อมูลเชิงอันดับ ranking
- เหมาะสำหรับกรณีที่ข้อมูลไม่เป็นปกติ หรือมี outliers มากจนค่าความสัมพันธ์เชิงเส้นไม่สามารถสะท้อนความจริงได้
- ต้องการดูแนวโน้มความสัมพันธ์ทั่วไป

Pearson Correlation

Variable	Human	Entropy	Edge	Parameter
Human	1.0	0.75	0.82	0.45
Entropy	0.75	1.0	0.61	0.38
Edge	0.82	0.61	1.0	0.5
Parameter	0.45	0.38	0.5	1.0

- Edge กับ human (r = 0.82): ความสัมพันธ์**เป็นบวกในระดับสูงมาก** หมายความว่า ยิ่งไอคอนมีเส้นขอบ รายละเอียด หรือลายเส้นที่ตรวจจับได้หนาแน่นมากเท่าไหร่ มนุษย์ก็จะรู้สึกว่าไอคอนนั้นซับซ้อนมากเท่านั้น (เป็นตัวชี้วัดความซับซ้อนที่ดีที่สุดในชุดนี้)
- Entropy กับ human (r = 0.75): ความสัมพันธ์**เป็นบวกในระดับสูง** หมายความว่า ยิ่งภาพมีพิกเซลที่กระจายตัวหลากหลายและคาดเดายาก (ข้อมูลไม่ซ้ำซาก) มนุษย์จะมองว่าซับซ้อนสูงตามไปด้วย
- Parameter กับ human (r = 0.45): ความสัมพันธ์**เป็นบวกในระดับปานกลาง** หมายความว่า ขนาดไฟล์ที่ใหญ่ขึ้น (จากการบีบอัดภาพที่มีรายละเอียดเยอะ) มีส่วนเกี่ยวข้องกับความซับซ้อน แต่อาจไม่แม่นยำเท่าการวัดด้วยเส้นขอบหรือเอนโทรปีโดยตรง

Spearman Correlation

icon	Human	Entropy	Edge Density %	Parameter
A	1.2	2.1	4.5	1
B	2.8	4.3	12.2	1
C	3.5	5.2	18.5	4
D	4.7	6.8	32.1	12
E	4.9	7.1	29.8	8

	Human rate
Entropy	0.95
Edge	0.90
Parameter	0.87

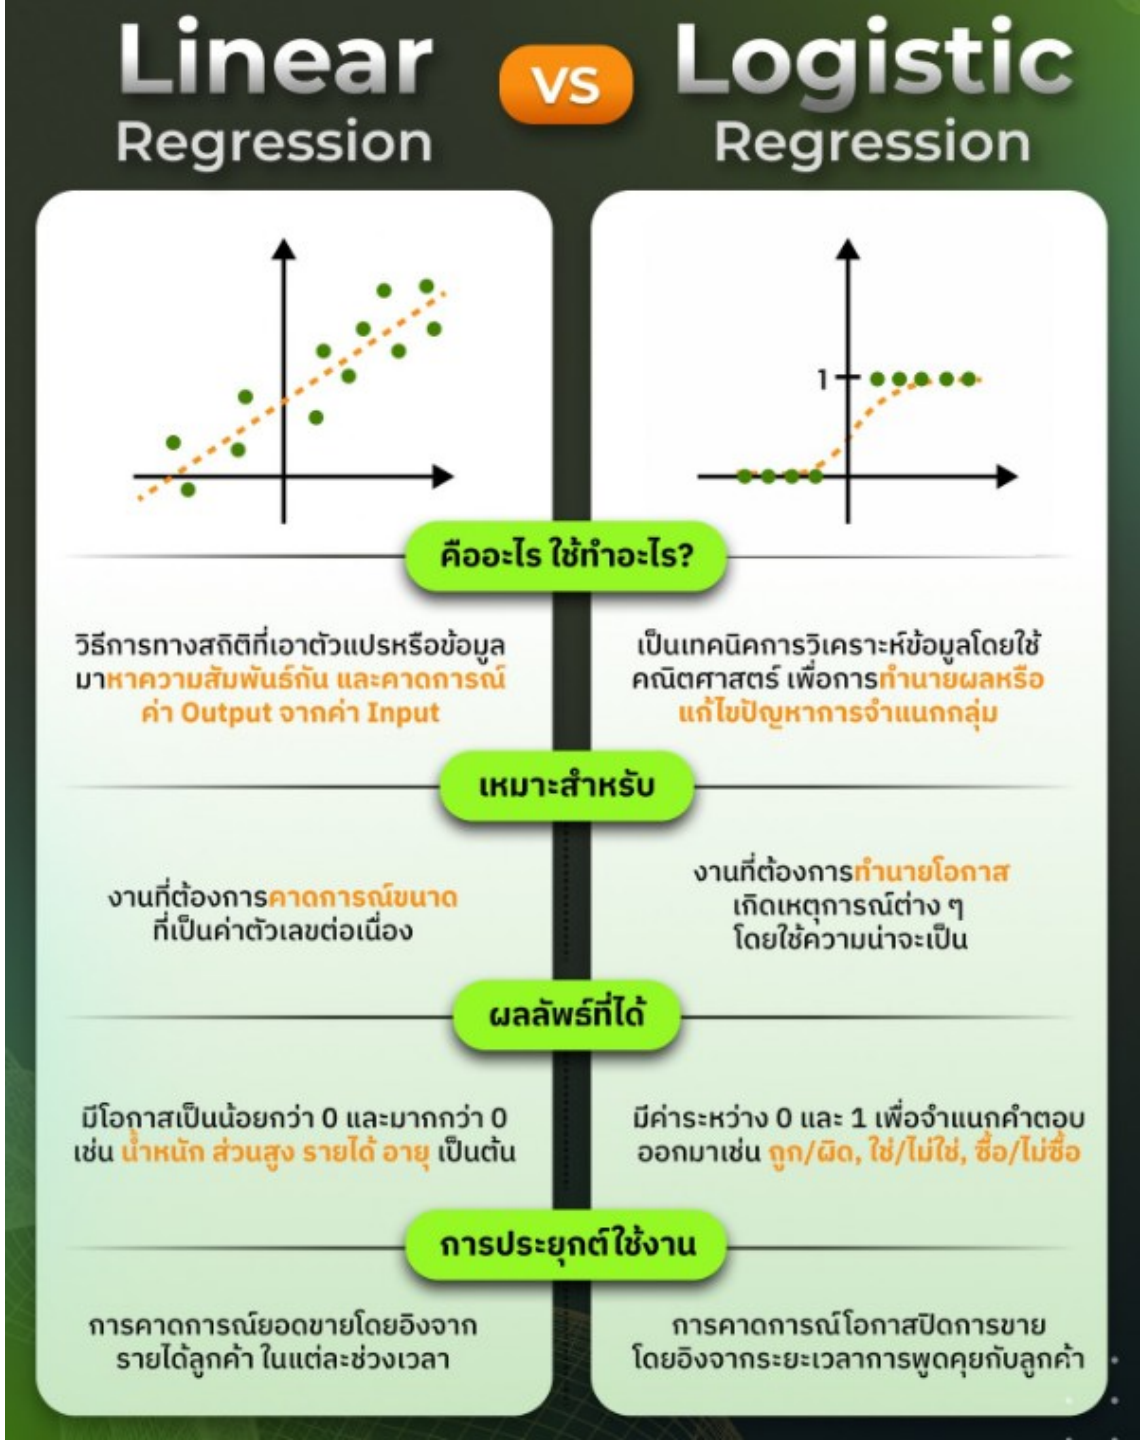
- "ค่า **entropy** เป็นตัวชี้วัดทางคอมพิวเตอร์ที่ดีที่สุดในการทำนายความซับซ้อนของไอคอน (**visual complexity**) เนื่องจากมีค่าความสัมพันธ์สเปียร์แมนสูงที่สุด (ρ = 0.95) อย่างมีนัยสำคัญทางสถิติ อย่างไรก็ตาม ค่า **edge** และ **parameter** ก็นับเป็นตัวชี้วัดที่มีประสิทธิภาพสูงเช่นกัน ซึ่งนักออกแบบสามารถนำอัลกอริทึมเหล่านี้ไปใช้ตรวจจับและควบคุมความซับซ้อนของไอคอนในระบบ **UI** แบบอัตโนมัติได้โดยไม่จำเป็นต้องใช้แรงงานคนประเมินซ้ำๆ

- ดูจากค่าตัวเลข ρ
- 0.80 **ถึง** 1.00: ความสัมพันธ์ในระดับ **สูงมาก;** 0.60 **ถึง** 0.79: ความสัมพันธ์ในระดับ **สูง;** 0.40 **ถึง** 0.59: ความสัมพันธ์ในระดับ **ปานกลาง**
- **entropy** (0.95) มีความสัมพันธ์กับความรู้สึกมนุษย์มากที่สุด รองลงมาคือ **edge** (0.90) และ **parameter** (0.87) ตามลำดับ

Regression

- วิธีทางสถิติที่ใช้หาความสัมพันธ์ระหว่างตัวแปร เพื่อทำนายอนาคตหรือผลลัพธ์ที่สนใจ
- ช่วยตอบคำถามว่า "ถ้าตัวแปรหนึ่งเปลี่ยน อีกตัวแปรจะเปลี่ยนตามอย่างไร“
- เอาไว้ดูแนวโน้ม
- ใช้ข้อมูลในอดีตมาสร้างเป็นสมการเพื่อทำนายสิ่งที่จะเกิดขึ้นในอนาคต
- ถ้าอ่านหนังสือมากขึ้น (X เพิ่มขึ้น) คะแนนสอบ (Y) ก็จะเพิ่มขึ้นตาม

Linear vs Logistic Regression



Sum up

Statistics

เปรียบเทียบค่าเฉลี่ย

- ANOVA : one-way, two-way
- T-test : paired t-test
- Repeated Measures

ข้อมูลเชิงกลุ่ม

- Chi-square test

หาความสัมพันธ์

- Correlation : Pearson, Spearman
- Regression : Linear, Logistic